

# Mundial Predictor 2026 | Resumen Ejecutivo

Laboratorio multiagente para razonar, predecir y evaluar partidos del Mundial 2026



## Tesis del proyecto

Demostrar que una arquitectura de agentes puede entender la lógica cambiante de un Mundial, comparar hipótesis contra un benchmark estadístico, ajustar pesos y confianza con resultados reales, y controlar costos con FinOps IA.



4

pronósticos  
por partido



1

benchmark ML  
reproducible



J1 / J2 / J3

routing y lógica  
por fase



USD 8.87–11.15

costo total  
proyectado



Contexto



Benchmark



Agentes



Evaluación



Ajuste



### Benchmark estadístico

- ELO + Poisson + XGBoost
- Piso reproducible y barato para comparar agentes



### Arquitectura multiagente

- Group Analyst, Tactical Scout, Sentiment Reader, Consensus
- Múltiples razonamientos para el mismo partido



### Evaluación real

- Predicción vs resultado real
- Ajuste de pesos, prompts y confianza por desempeño



### FinOps IA


- Cache, precomputación, RAG cerrado y rate limit
- DeepSeek Reasoner solo donde aporta valor



No es una app para apostar; es una demostración de arquitectura multiagente evaluable, trazabilidad y control de costos.

# Mundial Predictor 2026 | Arquitectura End-to-End

Cómo fluye el sistema desde los datos del torneo hasta el aprendizaje operativo y el control de costos.





# Mundial Predictor 2026 | FinOps IA & Control de Costos

Cómo el sistema decide cuándo usar IA, cuándo reutilizar resultados y cómo limita el gasto operativo.



## Tesis FinOps

La IA solo se invoca cuando aporta valor: primero se filtra, se cachea, se limita y se enruta por complejidad antes de llamar a un modelo costoso.

1



Pregunta del usuario

Consulta o solicitud de partido

2



Filtro de tema

Descarta consultas fuera del dominio fútbol

3



Cache SHA-256

Reutiliza respuestas repetidas con TTL

4



Rate limit

Control por IP y protección contra abuso

5



RAG cerrado

Contexto controlado: fixture, tabla y resultados

6



Routing DeepSeek

Flash / Chat / Reasoner según complejidad y fase

7



Respuesta + ledger

Entrega respuesta y registra costo operativo



### Ahorro

- Cache evita llamadas repetidas
- Precomputación evita generar narrativas por clic
- Fallback mantiene operación sin LLM



### Control

- Límite por IP
- Límite diario y mensual
- Routing por fase: J1 / J2 / J3 / Eliminatorias



### Métricas destacadas



USD 0.51  
gastado actual



USD 0.11–0.14  
por partido



USD 8.87–11.15  
proyectado



Reasoner solo para  
escenarios complejos



FinOps IA no significa usar menos IA; significa usar el modelo correcto, en el momento correcto y con control de costo.









Objetivo: entregar predicciones explicables, eficientes y confiables en cada jornada del Mundial 2026.

## ESTADO ACTUAL DEL SISTEMA



|   |             |    |
|---|-------------|----|
| ✓ | Completado  | 27 |
| ▶ | En progreso | 8  |
| 🕒 | Pendiente   | 5  |
| — | No iniciado | 2  |

## COBERTURA Y CAPACIDADES ACTUALES



## ROADMAP POR FASES



## PRIORIDADES CLAVE

- 

**Mejorar precisión del consenso**  
Ajustes dinámicos por jornada y fase del torneo.
- 

**Optimizar costos y latencia**  
Mayor uso de cache, precomputación y selección de modelos.
- 

**Aumentar cobertura y calidad**  
Más datos, mayor granularidad y contexto en tiempo real.
- 

**Escalabilidad y confiabilidad**  
Operación robusta para todo el Mundial 2026.

## HITOS CLAVE ENTREGADOS

|   |                                       |      |
|---|---------------------------------------|------|
| ✓ | Benchmark estadístico reproducible    | 100% |
| ✓ | Agentes especializados operando       | 100% |
| ✓ | RAG cerrado y contexto del torneo     | 100% |
| ✓ | Evaluación automática de predicciones | 100% |
| ✓ | Dashboard Mundial Predictor 2026      | 100% |
| ✓ | Control de costos (FinOps IA)         | 100% |

## PRÓXIMOS HITOS (90 DÍAS)

|    |                                              |          |
|----|----------------------------------------------|----------|
| 🧠  | Ajuste automático de pesos y confianza       | Ago 2025 |
| 📡  | Más fuentes en tiempo real (lesiones, clima) | Ago 2025 |
| 🗨️ | Narrativas generadas en tiempo real          | Sep 2025 |
| 🔗  | API pública v1                               | Oct 2025 |
| 🚀  | Operación full Mundial                       | Dic 2025 |

## MÉTRICAS DE ÉXITO 2026



>60%  
Exactitud 1X2



>55%  
Marcador exacto



<\$0.01  
Costo por predicción



<5 seg  
Tiempo de respuesta



# 7. ARQUITECTURA TECNOLÓGICA (STACK + DATA FLOW)

Tecnologías ligeras, modulares y orientadas a resultados con control de costos.




Diseñada para escalar la inteligencia del fútbol con eficiencia y control.

## STACK TECNOLÓGICO



## FLUJO DE DATOS END-TO-END



## STACK TECNOLÓGICO



PYTHON



PANDAS



SCIKIT-LEARN



XGBOOST



OPENAI  
EMBEDDINGS



DEEPSEEK  
LLM



STREAMLIT



PLOTLY



### ARQUITECTURA SIMPLE, ESCALABLE Y EFICIENTE.

Enfocada en decisiones inteligentes con el menor costo posible.



### Eficiencia Operativa

Menor costo por predicción



### Decisiones Confiables

Modelos + Agentes + Evaluación



### Inteligencia Continua

Aprende y mejora jornada a jornada